COMQUTOR Alpha 下一轮开发任务单

一、本轮目标与范围

本轮目标：用户看到的重要研究结论，能够追到真正支持它的来源；系统输出的验收结果，能够证明是按已确认规则计算出来的。

现有 Alpha 82.67%、Polarity 87.23% 的历史验证结果保留，不修改旧样本、旧预测或旧成绩。本轮检查的是修复后的实际产品流程，不将历史成绩自动继承为新版本的验证结果。Polarity 的既有成绩仅适用于固定目标 Alpha 下的判断，不代表当前 Alpha 与 Polarity 联合链路。

本轮不增加 Alpha、不训练自有模型、不开发自动交易、组合优化或完整 Feedback Loop。Alpha Memory 继续保持 shadow，不参与评分调整。

工作优先级

任务	优先级	本轮必须交付
T0：固定代码、输入和实际运行配置	前置任务	一份机器可读的运行清单
T1：修复来源到结论的关联	**P0**	可验证的证据关联链，以及 API、界面、导出一致性
T2：完成规则实际执行与 taxonomy 对齐	**P0**	有效规则、代码变更、自动测试和逐条判定
T3：核对实际模型配置，修复重点语义错误	**P1**	配置一致性证明、定向联合复核与错误明细
T4：生产环境、调用计量和实际演示	**P1**	PostgreSQL 验证、原始调用日志、测试结果、Demo 视频

先完成 T1、T2，再进行付费 Fresh Research。 规则和来源链路还没接通时，不再反复花钱重跑六个标的。

二、T0：固定本轮代码和输入

请从现有仓库创建本轮修复分支，记录真实 commit，不覆盖此前交付。

建立一份 `release_manifest.json`，至少包含：

类型	必须记录的内容
代码	分支、commit、是否存在未提交改动
数据	输入 run_id、输入文件位置、文件 hash、证据截止时间
配置	taxonomy 版本与 hash、验收规则版本与 hash

模型	各调用步骤的 provider、model、prompt hash，以及实际使用的 batch／单条路径
环境	数据库类型、关键依赖版本
执行类型	旧结果复评、冻结输入重算或 Fresh Run

三个执行类型不能混用：

旧结果复评：研究结果不变，只重新运行验收程序。

冻结输入重算：不获取新市场数据，但可能重新调用分类模型。

Fresh Run：重新获取数据并运行研究流程。

历史配置无法恢复时，明确标记缺失，不要用当前配置补写成历史信息。重新生成的结果应有自己的执行编号，并引用原始 run_id，不能覆盖原结果。

验收标准：从任一结果文件，能够找到它使用的代码、输入、模型和规则。

三、T1：修复来源追溯——本轮第一优先级

1. 当前问题

AMD 验证保存了 46 条来源，但 572 条 findings 中仅 2 条关联成功，34 条冲突证据中没有一条关联来源；当前关联主要依靠生成文本与来源标题匹配。

因此，不能只继续完善 Source Registry 的展示。**需要修的是来源身份在分析、抽取和评分过程中丢失的问题。**

2. 具体实现要求

请沿用现有模块修复，不必重建一套系统。目标链路为：

原始来源 / 数据记录

```
→ source_id + 可定位的内容片段
→ claim
→ evidence fact
→ Alpha / graph edge / conflict
→ API / UI / Export
```

A. 在取数阶段保存来源与可定位内容

新闻和公告至少保留真实的来源标识、标题、URL、发布时间、抓取时间，以及允许保存的原文片段或正文位置。

行情、财务和宏观数据至少保留数据提供方、指标、日期、单位、数据行及输入快照。技术指标或涨跌幅等派生结果，需要保留输入记录和计算方式，不能只引用模型写出的计算结论。

来源标题和 URL 只能证明来源存在，不能证明它支持某条结论。

对于历史回放，只能使用冻结时已保存、且符合证据截止条件的内容。旧 run 没有保存正文或数据行时，标记内容缺失，不能用后来发布的新闻补成“当时已有证据”。

B. Agent 和抽取模块传递已有来源 ID

给 Agent 的输入保留来源 ID 和片段 ID，结构化输出引用这些已有 ID。

后端必须校验：ID 是否存在、是否属于本次允许输入、原文片段或数据记录是否真实可定位。不能接受模型自行生成的 URL、source_id 或引文。

标题匹配可以作为辅助方法，但不能继续成为主要关联方式。

C. Evidence Fact 合并后保留来源链

去重时可以合并同一事实的表达，但不能丢掉原始引用。

同一财报被多个 Agent 引用，应保留这些引用关系，**不能因此增加独立证据数量**。不同来源提出相似判断，也不能仅凭文本相似就全部删除。

D. 区分“关联成功”和“证据支持正确”

至少分开记录两个状态，字段名可沿用现有实现：

检查	要回答的问题
来源关联	这条 claim 是否确实引用了某条已保存的来源内容?
内容支持	该内容是否支持这条 claim，还是反驳、背景、引用或不确定信息?

不能把 `SOURCE_LINKED` 直接当作“事实已验证”。

E. 下游与界面同步处理

没有合格依据的内容可以保留为评论、假设或待核查项，但不能作为已充分支持的证据，直接抬高 qualified Alpha 或 admitted conflict。

Research、Evidence、Conflict 和 Export 应读取同一份关联结果。用户点击重要结论，应当能看到对应的内容片段或计算依据，而不只是内部 ID。

3. 本任务如何验收

先把 **AMD 原有 34 条冲突证据**固定为问题清单，逐条输出：

原 `evidence_id`
原关联状态
现 `source_id / 内容位置`
来源内容是否可用
修复后关联状态
内容支持审核结果
是否继续用于冲突
未通过原因

原清单不能因为某条证据被移除就从报告中消失。应分别统计“原证据关联情况”和“修复后被采用、降级、排除的情况”。

同时，从修复后的流程中核查所有重要摘要结论、主导 Alpha 的关键依据，以及 admitted conflict 两侧的证据。

完成条件：

- 来源内容可用、且已确认可关联的固定样本，能够正确关联并贯通界面与导出。
- 不可用或不支持的证据有明确原因，并在下游正确降级。
- 已关联样本不仅 ID 有效，其内容也确实对应结论。

- 缺少来源不能靠伪造链接、批量挂载全部文章或隐藏条目解决。
- 若历史材料不足以验证链路，先标为未验证，再通过 T4 的有限 Fresh Run 补测。

本轮不要求所有普通评论都有外部链接，也不设“必须产生几条冲突”的数量指标；**但不能出现关键结论没有依据，却仍按充分验证结果展示。**

四、T2：完成规则执行，不再只维护规则副本

1. 当前问题

现有 YAML 列出了六类语义和 16 条“标的—允许冲突”配置，但自身注明不代表实现已经对齐；最新交付仍承认 `A102__A304`、`A201__A304` 与 taxonomy 存在差距。

这项是上一轮已经明确要求的工作，本轮必须实际关闭。

2. 具体实现要求

第一，补齐已确认的两组 taxonomy 关系。

把 `A102__A304`、`A201__A304` 作为有条件可评估的关系补入实际 taxonomy，并更新版本、变更记录及测试。

“允许评估”不等于自动成立，更不等于必须成为主冲突。

第二，落实六类规则的执行映射。

对以下六类规则逐项说明配置来源、适用对象、执行函数、触发条件和判定结果：

`must_detect_if_evidence_present`、`should_detect_if_supported`、`conditional_only`、`do_not_force`、`allowed_main_conflicts`、`forbidden_dominant_without_strong_evidence`。

已有等价字段可以保留，不必为名称重写模块；但不能只列出六个名字，而没有实际执行内容。

第三，统一正式验收入口。

正式验收显式读取指定规则文件和 taxonomy，不允许静默回退到旧版本。程序输出解析后的 `effective_rules`，所有验收表和摘要从同一结果生成。

规则缺失、类型未实现或 taxonomy 不兼容，应输出配置／执行错误，不能改成 `NOT_APPLICABLE` 后继续 PASS。

第四，保持研究与 Gold 验收分离。

Gold 标签不能作为目标答案输入研究 Agent，也不能为了符合允许列表而改写研究输出。

例如，NVDA 当前的 `A304__A601` 继续保留为待审核结果；QQQ 新 run 的 PASS 不能替代旧 run 尚未关闭的复核。

3. 必须提供的自动测试

测试场景	预期行为
有明确支持证据，却漏掉必须识别的 Alpha	验收能够发现漏检

没有支持证据	不强制激活 Alpha 或生成冲突
只有反驳、引用或背景文字	不当成该 Alpha 的有效支持
必需规则缺失或无法执行	报错，不产生正式 PASS
同源证据增加多份重复表达	不重复抬高证据强度
实际冲突不在标的验收列表	保留研究输出，转入复核，不改答案
同一输入做纯 replay，只更换执行编号	不因 run_id 变化产生无依据的研究结论变化

测试可以使用明确标注的合成 fixtures，但不能把它们计为真实市场验证样本。

验收标准：交付代码 diff、有效规则、原始测试结果，以及六个历史标的的逐条规则判定。不是只交一份写着 FROZEN 的 YAML。

五、T3：核对实际模型，并修复最有影响的语义错误

1. 先确认验证与产品使用的是不是同一配置

最终 Alpha 验证摘录使用 Anthropic／`claude-sonnet-4-6`，而性能报告将 NVDA、QQQ 的研究运行归入 DeepSeek 通道。目前需要补齐分步骤路由，才能判断验证成绩是否适用于实际 Alpha 分类步骤。

请提交如下配置对照，不要求所有 Agent 使用同一模型：

步骤	实际产品配置	对应验证配置	是否一致／差异影响
Structured Adapter	provider、model、prompt、代码版本	对应记录	说明
Alpha Classifier	同上，并注明 batch／单条路径	150 条验证所用配置	说明
Polarity Classifier	同上	H2 所用配置	说明
Structure Extractor	同上	对应记录	说明

若产品 Alpha 分类配置不同，应使用当前部署配置进行验证。不能把另一配置的成绩直接算到产品头上。

2. 修复顺序

先处理 A304 误报，再检查 A101／A103 的边界。

现有 Alpha 测试中，A304 被输出 16 次，仅 6 次与 Gold 相符；另外，A001、A003、A102、A501 没有 Gold 样本覆盖。

请从原始错误样本检查，不要仅靠调整全局阈值。重点区分：

提到了估值、讨论估值风险、反驳估值风险、提出条件性风险、已有数据支持估值压缩。

保持现有 Taxonomy 的定义；发现定义确有歧义时单独提出，不要在代码中悄悄改变产品含义。也不能通过全部不输出 A304 来“解决”误报。

3. 增加一组有限的联合复核，不重建大型测试项目

本轮准备 **40 条定向复核样本**：

场景	数量
A304 边界：支持、反驳、引用、条件和背景	16
A101／A103 易混边界	8
A001、A003、A102、A501，各 4 条	16
合计	**40**

这是一组**定向诊断集，不是市场总体代表性样本**。按场景选择材料，不预设它们必须被识别成某个 Alpha；其中应包含实际进入重要结论的证据，不能全部是人为编写的简单句。

样本应附原始来源片段、适用对象和时间。预测前固定样本和配置；参考判定由 John 或指定复核人完成，审核时不展示系统答案。没有人工审核的部分明确保留待审核，不能自行标记 `john_approved=true`。

每条联合检查：

来源内容
→ `claim` 是否忠实
→ `Alpha` 是否正确
→ 对该 `Alpha` 的支持 / 反对方向是否正确
→ 是否应进入 `activation / admitted conflict`

报告须同时给出总体准确率、非 NONE 预测精确率、召回率、各类样本量、混淆矩阵、弃权及调用失败数。不能把解析失败当作正确的 `NONE`，也不能只展示总体 accuracy。

本轮不追溯改变原定 80% 目标，也不把这 40 条包装成新的“全部 Alpha 已验证”。 发现错误后保留真实成绩；已用于修复的样本转入开发回归，不再称独立盲测。

六、T4：目标环境、成本计量和实际演示

1. 在 PostgreSQL 上验证，不以 SQLite 回退结果代替

此前来源追溯验证使用 SQLite；报告还保留一个 replay/run_id 相关测试失败和两项 ESLint 问题。

本轮请完成：

数据库迁移、来源持久化、服务重启、历史重新打开、结果导出，以及 run_id 与原始输入关系的一致性验证。

测试环境必须明确显示 PostgreSQL，不允许静默回退 SQLite 后仍按生产环境通过报告。

对 `test_replay_conflict_does_not_get_run_id_mismatch` 提交根因及修复结果。若认为测试本身错误，需要用预期行为和复现依据说明，不能仅标“既有问题、不相关”。两项 ESLint 问题一并处理或明确其处理决定。

本轮必跑的相关测试不得通过跳过、删除断言或引用历史通过数量来关闭。

2. 补齐调用与费用计量，暂不承诺激进提速

此前 NVDA、QQQ 分别记录 819、812 次 semantic 调用，但 token 和费用不可用。

请对每次实际调用记录：

`run_id`、步骤、`provider`、`model`、请求标识
开始与结束时间
成功 / 失败 / 超时 / 重试
输入与输出 `token`（若 `provider` 返回）
缓存命中情况
费用实测值或估算依据

上游 Agent 数量、实际模型请求数、重试请求数分开统计，不能混为一项。

provider 未返回 usage 时，保留未知并报告缺失比例；不要编造 token 或按耗时推算费用。日志不得包含 API key、访问令牌或其他秘密。

本轮先完成计量，再决定优化目标。可以做低风险的空文本过滤、过程性文本过滤和确定性重复缓存，但不能通过删除有效证据降低调用次数。

3. 只要求一次必要的 Fresh 验证

T1、T2 离线通过后，**默认选择 NVDA 做一次最新代码、实际模型路由、PostgreSQL 环境的 Fresh Run**。运行前固定配置和调用预算。

AMD 用于原 34 条冲突证据的追溯回归；QQQ 用冻结数据检查规则和证据；SNDK 保留历史无主冲突展示。确需第二次 Fresh 才能验证的问题，先说明目的，不默认重跑六个标的。

Fresh Run 不要求出现指定 Alpha 或冲突，但必须证明来源传递、实际配置、状态处理和产物保存正常工作。

4. 提交实际 Demo 视频

录制一次可核查的走查：

`Research`
→ 点击重要结论
→ 原始证据片段 / 数据依据
→ `Structure Graph`
→ `Conflict Radar`
→ 历史重新打开
→ `Export`

同时展示“证据不足”“没有主冲突”以及一次通过测试注入的失败／部分完成状态。模拟状态必须注明，不能冒充真实市场运行。

视频中标出代码版本和 run_id。冻结 Demo 与 Fresh Research 清楚区分。

七、最终交付与签收标准

只提交一个统一交付包，沿用已有目录和文件名即可，但入口清单必须指向唯一版本：

交付部分	必须包含
代码与配置	commit、diff、实际有效规则、taxonomy、运行配置
来源验证	AMD 固定问题清单、关键结论的来源关联与内容核查结果
测试与语义验证	原始样本、逐条预测、审核记录、自动生成的统计、测试日志
实际运行	完整 artifacts、原始调用记录、PostgreSQL 验证、Fresh Run metadata
使用证明	Demo 视频和一份可复制执行的 README

README 不必很长，但应给出真实可运行的启动、回放和测试命令。不能只提供工程师电脑上的绝对路径、文件 hash 或统计摘录，而不提供被引用的实际内容。

本轮如何签收

按任务分别签收，不要求所有报告都变成绿色 PASS：

- 来源机制通过，必须同时有正确关联和内容支持的证据，不能只证明来源表已保存。
- 规则执行通过，必须有实际加载、运行和错误路径测试，不能只有配置副本。
- 语义验证必须对应实际模型配置，保留错误和覆盖限制。
- 环境验证必须在目标数据库执行，不能用旧测试记录代替。
- NVDA、QQQ 尚未关闭的具体争议继续单独记录，不能通过换一个成功 run 消除。

若关键结论仍使用没有依据的证据，或规则缺失仍能产生正式 PASS，本轮相关任务就不能关闭。

重点只有四个问题：

改了哪段代码？用什么输入运行？实际结果是什么？还有什么没有通过？

先把这四个问题用代码和原始记录回答清楚，再冻结内部 Demo 版本，不继续扩写“全部完成”的总结文档。